

Comparative Analysis of Deep Learning Architectures for Retinal OCT Image Classification: CNN, Vision Transformer, and Hybrid Models with GAN-Based Data Augmentation

Jose Chuque - Iago Evangelista - Rodrigo Puente

Facultad de Ingeniería de Sistemas - UNMSM

jose.chuquec@unmsm.edu.pe , iago.evangelista@unmsm.edu.pe , rodrigo.puente@unmsm.edu.pe

Resumen

El diagnóstico de patologías retinianas mediante tomografía de coherencia óptica (OCT) es un proceso manual propenso a variabilidad. Este estudio comparó cuatro arquitecturas de aprendizaje profundo (ResNet-50, EfficientNet-B3, ViT-B/16 y CoAtNet), representantes de los paradigmas convolucional, de atención e híbrido, para clasificar imágenes OCT en cuatro categorías (CNV, DME, Drusen y Normal). Se evaluó también el impacto del aumento de datos sintéticos mediante una red generativa adversarial (DCGAN).

Utilizando 2,000 imágenes reales por clase del dataset de Kermany et al. (2018), se establecieron dos escenarios: sin aumento (A) y con un 30% de imágenes sintéticas (B). El desempeño se midió mediante métricas de exactitud, precisión, sensibilidad, F1-score y AUC-ROC, además de análisis de eficiencia, interpretabilidad con Grad-CAM y validación estadística con la prueba de McNemar.

Los resultados mostraron exactitudes entre 95.66% y 99.17% sin una arquitectura dominante. La prueba de McNemar confirmó que el uso de GAN no generó mejoras estadísticas significativas ($p > 0.05$). Las redes convolucionales ofrecieron explicaciones visuales más focalizadas, mientras que el número de parámetros no determinó la eficiencia temporal. Estos hallazgos proporcionan evidencia para seleccionar arquitecturas en medicina considerando precisión, eficiencia e interpretabilidad.

Palabras clave: tomografía de coherencia óptica, aprendizaje profundo, redes generativas adversariales, Vision Transformer, interpretabilidad, Grad-CAM.

1. INTRODUCCIÓN

Las enfermedades retinales constituyen una de las principales causas de discapacidad visual y ceguera irreversible a nivel mundial. Entre las patologías de mayor prevalencia clínica se encuentran la neovascularización coroidal (CNV), el edema macular diabético (DME) y el drusen, condiciones que, si no son detectadas oportunamente, pueden derivar en pérdida permanente de la visión. La tomografía de coherencia óptica (OCT) se ha consolidado como la modalidad de imagen de referencia para el diagnóstico de estas enfermedades, gracias a su capacidad de generar cortes transversales de alta resolución de las capas retinales de manera no invasiva. Sin embargo, la interpretación manual de estas imágenes demanda especialistas altamente entrenados, consume tiempo considerable y está sujeta a variabilidad inter-observador, lo que limita su escalabilidad en sistemas de salud con alta demanda asistencial. Este contexto adquiere mayor urgencia considerando que, según estimaciones del Global Burden of Disease Study, las enfermedades retinales figuran entre las principales causas prevenibles de ceguera y discapacidad visual a nivel mundial, con una carga que sigue creciendo conforme envejece la población global (Steinmetz et al., 2021).

Ante este panorama, el aprendizaje profundo ha emergido como una solución prometedora para automatizar el diagnóstico a partir de imágenes médicas. El trabajo seminal de Kermany et al. (2018) demostró que arquitecturas de redes neuronales convolucionales entrenadas sobre grandes volúmenes de imágenes OCT podían alcanzar niveles de precisión diagnóstica comparables a los de oftalmólogos expertos, marcando un hito en la aplicación de inteligencia artificial al diagnóstico retinal. Desde entonces, arquitecturas como ResNet (He et al., 2016) y los Vision Transformers (Dosovitskiy et al., 2020) han ampliado considerablemente el horizonte de posibilidades, introduciendo paradigmas de aprendizaje de características locales y globales respectivamente.

No obstante, la literatura científica existente presenta una brecha metodológica relevante: la mayoría de los estudios comparan arquitecturas bajo condiciones heterogéneas, con datasets desbalanceados o de tamaño variable, lo que dificulta atribuir las diferencias de rendimiento a las arquitecturas mismas y no a factores externos. Adicionalmente, el impacto del aumento de datos sintéticos generados mediante redes generativas adversariales (GAN) sobre el rendimiento de distintas familias de arquitecturas en OCT retinal ha sido escasamente explorado de manera sistemática y controlada.

El presente estudio aborda esta brecha mediante un diseño experimental estrictamente controlado que compara cuatro arquitecturas representativas de distintos paradigmas: ResNet-50 y EfficientNet-B3 como arquitecturas CNN, ViT-B/16 como modelo basado en mecanismos de auto-atención global, y CoAtNet como arquitectura híbrida CNN-Transformer. El experimento se desarrolla sobre un subconjunto estratificado y balanceado del dataset OCT de Kermany et al. (2018), fijando 2,000 imágenes por clase para aislar el efecto de la arquitectura. Adicionalmente, se evalúa el impacto de incorporar imágenes sintéticas generadas por GAN para simular escenarios de escasez de datos médicos, condición frecuente en la práctica clínica real.

Las contribuciones principales de este trabajo son: (a) una comparación controlada y reproducible de cuatro paradigmas de aprendizaje profundo para clasificación OCT retinal bajo las mismas condiciones de datos y entrenamiento; (b) la evaluación del impacto de la augmentación sintética mediante GAN sobre el rendimiento de cada arquitectura; (c) el análisis de interpretabilidad mediante Grad-CAM para validar la coherencia clínica de las decisiones de cada modelo; y (d) la validación estadística de las diferencias de rendimiento entre configuraciones. El resto del artículo se organiza de la siguiente manera: la Sección 2 presenta los trabajos relacionados, la Sección 3 describe los

materiales y métodos, la Sección 4 reporta los resultados experimentales, la Sección 5 desarrolla la discusión y la Sección 6 presenta las conclusiones.

2. TRABAJOS RELACIONADOS

2.1. Clasificación de OCT Retinal con CNN

La aplicación de inteligencia artificial al diagnóstico retinal responde a una necesidad clínica ampliamente documentada. Daich Varela et al. (2023) ofrecen una revisión exhaustiva sobre el estado actual, los desafíos de validación clínica y las direcciones futuras de los modelos de IA aplicados a enfermedades retinales, concluyendo que la integración de estos sistemas en la práctica clínica requiere no solo alta precisión diagnóstica, sino también interpretabilidad y robustez ante condiciones de datos heterogéneos. Sobre esta base, el trabajo fundacional de Kermany et al. (2018) demostró que arquitecturas CNN podían alcanzar niveles de precisión diagnóstica comparables a los de oftalmólogos expertos en imágenes OCT, estableciendo el estándar del dataset ampliamente empleado en la literatura posterior. Sobre esta base, Yang et al. (2025) propusieron CRAT, un modelo basado en mecanismos de atención avanzados evaluado sobre nueve arquitecturas de referencia, demostrando que las variantes con atención superan consistentemente a las CNN clásicas en clasificación OCT. En una línea similar, Gencer y Gencer (2025) desarrollaron un modelo que integra bloques Squeeze-and-Excitation con EfficientNetB0 y Xception, alcanzando precisiones de 99.58% y 99.18% en los conjuntos UCSD y Duke respectivamente. Abdi y Abdulazeez (2025) sintetizaron el estado del arte en segmentación y clasificación OCT mediante aprendizaje profundo, destacando que los modelos compactos basados en ResNet y variantes de EfficientNet mantienen ventajas prácticas en escenarios con datos limitados. Complementariamente, P et al. (2020) propusieron OctNET, una arquitectura ligera que, empleando solo el 6.9% de los parámetros de ResNet-50, logra superarlo en la clasificación de CNV, DME y drusen, subrayando la importancia de la eficiencia paramétrica en aplicaciones clínicas con recursos restringidos.

2.2. Vision Transformers en Imágenes Médicas

A diferencia de las convoluciones, que operan sobre vecindades locales, los Vision Transformers dividen la imagen en parches y modelan relaciones globales mediante mecanismos de auto-atención (Dosovitskiy et al., 2020), lo que les confiere mayor capacidad para capturar dependencias espaciales de largo alcance. Aburass et al. (2025) ofrecen la revisión más reciente sobre aplicaciones de ViT en imagen médica, concluyendo que, si bien los Transformers superan a las CNN cuando se dispone de grandes volúmenes de datos de preentrenamiento, su rendimiento en datasets médicos pequeños es más limitado debido a la ausencia de inducción de sesgo local. En el ámbito oftalmológico, Cutur e Inan (2025) demostraron que el fine-tuning específico del dominio con backbones ViT puede lograr mejoras significativas frente a líneas base CNN incluso con subconjuntos balanceados de poco más de 4,000 imágenes. Ahmed y Uddin (2025) propusieron OcuViT, basado en ViT-Base-Patch16-224, para clasificación de retinopatía diabética y degeneración macular, abordando el problema de eficiencia computacional que ha limitado la adopción clínica de los Transformers. Goh et al. (2024) compararon ViT y CNN en detección de retinopatía diabética, concluyendo que ambas familias son competitivas pero que los ViT requieren estrategias de regularización más estrictas en escenarios con datos limitados. Finalmente, Arbab et al. (2025) analizaron el comportamiento específico de los ViT en clasificación OCT, aportando evidencia sobre sus limitaciones cuando no se compensa la escasez de datos con un preentrenamiento robusto.

2.3. Arquitecturas Híbridas CNN-Transformer

El reconocimiento de las limitaciones complementarias de CNN y ViT ha motivado el desarrollo de arquitecturas híbridas que combinan la eficiencia local de las convoluciones con la capacidad de modelado global de los Transformers. Azad et al. (2023) revisaron más de 200 trabajos sobre esta tendencia en imagen médica, concluyendo que los enfoques híbridos representan la dirección dominante en tareas de alta complejidad visual al ofrecer un equilibrio más favorable entre capacidad representacional y requisitos de datos. Kim et al. (2025) respaldaron esta evidencia mediante una revisión sistemática bajo criterios PRISMA de 34 arquitecturas híbridas CNN-ViT para tareas radiológicas, estableciendo que superan consistentemente a sus contrapartes puras tanto en clasificación como en segmentación. Rajatha y Ashoka (2025) introdujeron EffViT, un framework que combina EfficientNet-B4 como encoder multiescala con bloques Vision Transformer para análisis retinal, alcanzando un AUC de 0.9466 y una mejora del 5.17% respecto a las tecnologías previas en la misma tarea. Liu y Shen (2023) desarrollaron CECT, un modelo de ensemble CNN-Transformer de configuración controlable que captura características a múltiples escalas sin módulos de diseño complejo adicionales, demostrando robustez en evaluación inter-dataset con una precisión del 98.1%.

2.4. Aumento de Datos Sintéticos con GAN

La escasez de datos anotados representa uno de los principales obstáculos para entrenar modelos de aprendizaje profundo en el dominio médico, donde la recopilación y etiquetado de imágenes clínicas requiere tiempo y expertise especializado. Las redes generativas adversariales han emergido como una solución para mitigar este problema mediante la generación de imágenes sintéticas de alta fidelidad. Chen et al. (2022) presentaron una revisión sistemática de 105 trabajos sobre augmentación de imágenes médicas con GAN, cubriendo múltiples modalidades y patologías, y concluyendo que las imágenes sintéticas generadas por GAN mejoran consistentemente el rendimiento de clasificación en escenarios con datos limitados, siempre que la calidad generativa sea suficiente. En el dominio retinal específicamente, Anaya-Sánchez et al. (2024) propusieron un método basado en WGAN-GP para generar imágenes sintéticas de retinopatía diabética, alcanzando un FID de 15.21 y demostrando que solo el 56.66% de las imágenes sintéticas podía ser distinguido de imágenes reales por evaluadores expertos, lo que evidencia su alto potencial para enriquecer datasets en entornos de escasez de datos clínicos.

2.5. Técnicas de Interpretabilidad: Grad-CAM

La adopción clínica de modelos de aprendizaje profundo no depende únicamente de su precisión, sino también de su capacidad para explicar las regiones de la imagen que fundamentan cada decisión diagnóstica. Grad-CAM, propuesto por Selvaraju et al. (2019), es la técnica de interpretabilidad más ampliamente adoptada en imagen médica: utiliza los gradientes del concepto objetivo fluyendo hacia la última capa convolucional para producir mapas de calor que destacan las regiones de mayor relevancia en la predicción. Su aplicabilidad a diversas familias de CNN, sin requerir modificaciones arquitectónicas, lo convierte en una herramienta especialmente adecuada para la validación clínica de

modelos en tareas de clasificación retinal, donde la correspondencia entre las regiones activadas y los hallazgos anatómicos esperados sirve como criterio de confiabilidad diagnóstica.

3. MATERIALES Y METODOLOGÍA

3.1. Descripción del Dataset y Preprocesamiento

Para el desarrollo del presente estudio se utilizó el conjunto de datos público de imágenes de Tomografía de Coherencia Óptica (OCT) retiniana, originalmente compilado y publicado por Kermany et al. (2018). Este dataset ha sido ampliamente adoptado como referencia estándar en estudios de clasificación de enfermedades retinianas mediante aprendizaje profundo, lo que permite comparar los resultados del presente trabajo con investigaciones previas bajo condiciones experimentales similares.

El dataset está compuesto por imágenes en escala de grises correspondientes a cuatro categorías diagnósticas: Neovascularización Coroidea (CNV), Edema Macular Diabético (DME), Drusen, y retina sin patología (Normal). En su versión original, el conjunto presenta un marcado desbalance entre clases, con la categoría CNV conteniendo aproximadamente 37,200 imágenes en el subconjunto de entrenamiento, frente a 8,616 imágenes en la clase Drusen, la menos representada.

Dado este desbalance, y con el objetivo de garantizar una comparación equitativa entre las arquitecturas evaluadas, se realizó un muestreo aleatorio balanceado de 2,000 imágenes por clase para el conjunto de entrenamiento, y de 350 imágenes por clase para el conjunto de validación, ambas extraídas del subconjunto train original mediante una semilla aleatoria fija para garantizar la reproducibilidad del proceso. Esta decisión es consistente con lo señalado por Mosquera et al. (2024), quienes demostraron que el desbalance de clases no corregido en la clasificación de imágenes médicas puede distorsionar tanto las métricas de discriminación como de calibración del modelo, recomendando prácticas de evaluación que controlen explícitamente este factor. Para el conjunto de prueba, se utilizó el subconjunto test oficial del dataset, el cual ya se encuentra balanceado de origen (242 imágenes por clase), preservando así la comparabilidad con estudios previos que han empleado el mismo split oficial.

El pipeline de preprocesamiento aplicado a las imágenes, idéntico para las cuatro arquitecturas evaluadas con el fin de garantizar una comparación válida, consistió en las siguientes etapas:

- **Conversión de canal:** las imágenes originales en escala de grises (1 canal) fueron replicadas a 3 canales, requisito de las arquitecturas pre-entrenadas en ImageNet utilizadas en este estudio.
- **Redimensionamiento:** todas las imágenes fueron escaladas a una resolución uniforme de 224×224 píxeles, tamaño compatible de forma nativa con las cuatro arquitecturas evaluadas, evitando así que diferencias en resolución de entrada introdujera sesgos en la comparación de eficiencia computacional.
- **Normalización:** los valores de píxel fueron normalizados utilizando la media y desviación estándar del conjunto ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$),

consistente con el uso de transferencia de aprendizaje (transfer learning) en las cuatro arquitecturas.

- **Aumento de datos tradicional:** exclusivamente sobre el conjunto de entrenamiento, se aplicaron transformaciones de flip horizontal aleatorio ($p=0.5$) y rotación aleatoria leve ($\pm 7^\circ$), con el fin de mejorar la capacidad de generalización del modelo sin alterar las características diagnósticas relevantes de las imágenes. Estas transformaciones se aplicaron de manera idéntica en ambos escenarios experimentales (con y sin aumento de datos vía GAN, ver Sección 3.3), de forma que la única variable diferenciadora entre escenarios fuera la presencia de imágenes sintéticas generadas mediante GAN.

3.2. Arquitecturas Evaluadas

3.2.1. ResNet-50

ResNet-50 es una arquitectura de red neuronal convolucional de 50 capas, perteneciente a la familia de Redes Residuales (Residual Networks) propuesta originalmente por He et. al. (2016), cuya principal innovación radica en la incorporación de conexiones residuales (skip connections) que permiten mitigar el problema de desaparición del gradiente (vanishing gradient) en redes profundas, facilitando así el entrenamiento de modelos con mayor número de capas sin degradación del desempeño.

En el presente estudio, se utilizó una versión de ResNet-50 pre-entrenada en el conjunto de datos ImageNet, sobre la cual se aplicó una estrategia de transferencia de aprendizaje (transfer learning) mediante ajuste fino parcial (partial fine-tuning). Esta estrategia resulta particularmente adecuada cuando se dispone de un volumen limitado de datos médicos, como señalan Ayana et al. (2024), quienes advierten que el ajuste fino completo de redes pre-entrenadas en dominios con escasez de datos incrementa el riesgo de sobreajuste al conservar excesiva dependencia de las características aprendidas en el dominio fuente. Específicamente, se congelaron los parámetros de las primeras tres etapas convolucionales de la red, dado que estas capas iniciales capturan características visuales de bajo nivel (bordes, texturas, gradientes de intensidad) que resultan generalizables tanto a imágenes naturales como a imágenes médicas. Por el contrario, se permitió el reentrenamiento del último bloque residual (layer4), donde la red aprende representaciones de más alto nivel y semánticamente específicas del dominio, permitiendo así su adaptación a los patrones característicos de las imágenes OCT retinianas.

La capa de clasificación final, originalmente diseñada para discriminar entre las 1,000 categorías del conjunto ImageNet, fue reemplazada por una capa totalmente conectada (fully connected) con cuatro neuronas de salida, correspondientes a las cuatro categorías diagnósticas evaluadas en este estudio: Neovascularización Coroidea (CNV), Edema Macular Diabético (DME), Drusen, y Normal.

3.2.2. EfficientNet-B3

EfficientNet es una familia de arquitecturas de redes neuronales convolucionales propuesta por Tan y Le (2019), cuya principal contribución es el método de escalamiento compuesto (compound scaling), el cual ajusta de manera uniforme y simultánea tres dimensiones de la red mediante un conjunto fijo de coeficientes, a diferencia de enfoques previos que escalaban estas dimensiones de forma independiente y poco sistemática. La arquitectura se construye sobre bloques MBConv (Mobile

Inverted Bottleneck Convolution) y emplea convoluciones separables en profundidad para mejorar la eficiencia de parámetros.

Dentro de esta familia, EfficientNet-B3 corresponde a un modelo de tamaño intermedio que ofrece un balance entre costo computacional y precisión, obtenido a partir del modelo base EfficientNet-B0 mediante un multiplicador de ancho de $1.2\times$, un multiplicador de profundidad de $1.4\times$, y una resolución de entrada de 300×300 píxeles en su configuración original. Para efectos del presente estudio, las imágenes de entrada fueron redimensionadas a 224×224 píxeles, con el propósito de mantener consistencia dimensional con las demás arquitecturas evaluadas, evitando así que diferencias en la resolución de entrada introdujera sesgos en el análisis comparativo de eficiencia computacional (ver Sección 3.1).

De manera análoga a la estrategia aplicada en ResNet-50, se utilizó una versión de EfficientNet-B3 pre-entrenada en ImageNet, congelando los parámetros correspondientes a los bloques convolucionales iniciales y permitiendo el reentrenamiento únicamente del último bloque MBConv, donde se concentran las representaciones de mayor especificidad semántica. El clasificador final fue reemplazado por una capa totalmente conectada con cuatro neuronas de salida, precedida por una capa de regularización por dropout, manteniendo así la estructura de regularización original de la arquitectura.

3.2.3. Vision Transformer (ViT-B/16)

El Vision Transformer (ViT) fue propuesto por Dosovitskiy et al. (2020) como una adaptación de la arquitectura Transformer al dominio de la visión por computadora. A diferencia de las redes neuronales convolucionales tradicionales, ViT divide la imagen de entrada en parches de tamaño fijo, los cuales son embebidos linealmente y procesados mediante un codificador Transformer (Transformer encoder) para capturar información contextual global.

La notación "B/16" en ViT-B/16 indica que se trata de la variante Base del modelo, en la cual se aplica atención global sobre parches de 16×16 píxeles a lo largo de toda la imagen, permitiendo capturar las características salientes globales de la imagen y resolver las dependencias de largo alcance entre distintas regiones del contenido visual. Esta capacidad de modelar relaciones globales entre regiones distantes de la imagen constituye la principal diferencia conceptual frente a las arquitecturas convolucionales descritas previamente (Secciones 3.2.1 y 3.2.2), las cuales procesan la información de manera local mediante filtros convolucionales.

De forma consistente con la estrategia aplicada a las arquitecturas anteriores, se utilizó una versión de ViT-B/16 pre-entrenada en ImageNet, congelando los parámetros de los primeros once bloques del codificador Transformer y permitiendo el reentrenamiento únicamente del último bloque, donde se concentran las representaciones contextuales más específicas para la tarea de clasificación. La cabeza de clasificación (classification head) original fue reemplazada por una capa totalmente conectada con cuatro neuronas de salida, correspondientes a las categorías diagnósticas evaluadas en este estudio.

3.2.4. Arquitectura Híbrida (CoAtNet)

CoAtNet fue propuesta por Dai et al. (2021) como una arquitectura híbrida que combina de manera estructurada los principios de las redes convolucionales y los modelos Transformer, con el objetivo de aprovechar simultáneamente las fortalezas de ambos paradigmas. El diseño se fundamenta en dos

ideas centrales: primero, que la convolución en profundidad (depthwise convolution) y la auto-atención (self-attention) pueden unificarse de manera natural mediante un mecanismo de atención relativa; segundo, que el apilamiento vertical de capas convolucionales y capas de atención, realizado de forma sistemática, resulta sorprendentemente efectivo para mejorar la generalización, la capacidad y la eficiencia del modelo.

A diferencia de las arquitecturas híbridas que combinan CNN y Transformer mediante ramas paralelas, CoAtNet adopta una estrategia secuencial en la que las características extraídas por múltiples bloques MBConv (los mismos bloques convolucionales empleados en EfficientNet, Sección 3.2.2) son posteriormente procesadas por bloques de tipo Transformer, capitalizando así la capacidad de extracción de características locales propia de las CNN junto con la conciencia de contexto global característica de los Vision Transformers. Esta estructura permite que el modelo alcance un desempeño comparable al de ViT-B/16 (Sección 3.2.3) con menores requerimientos de datos de entrenamiento.

Para los fines de este trabajo, se utilizó la variante CoAtNet-0, la más ligera de la familia, configurada de forma nativa para una resolución de entrada de 224×224 píxeles, consistente con la resolución empleada en las demás arquitecturas evaluadas. Cabe señalar que, si bien la configuración original de CoAtNet emplea valores de normalización distintos a los del conjunto ImageNet, en el presente estudio se optó por mantener la normalización basada en las estadísticas de ImageNet (Sección 3.1) de manera uniforme para las cuatro arquitecturas evaluadas, con el fin de preservar la validez del análisis comparativo y evitar que diferencias en el preprocesamiento de entrada constituyeran una variable de confusión adicional.

3.3. Generación de Datos Sintéticos mediante GAN

3.3.1. Arquitectura GAN y Entrenamiento

Para la generación de imágenes sintéticas se empleó una Red Generativa Adversarial Convolucional Profunda (DCGAN), propuesta originalmente por Radford et al. (2015). Esta arquitectura está compuesta por dos redes neuronales entrenadas de manera adversarial: un Generador, encargado de transformar un vector de ruido aleatorio en una imagen sintética, y un Discriminador, encargado de distinguir entre imágenes reales y generadas. Ambas redes se entrenan de forma simultánea mediante un proceso de optimización de minimax, en el cual el Generador busca producir imágenes cada vez más realistas mientras el Discriminador mejora progresivamente su capacidad de detección.

Dado que las cuatro categorías diagnósticas del conjunto de datos (CNV, DME, Drusen y Normal) presentan patrones visuales claramente diferenciados entre sí, se optó por entrenar un modelo DCGAN independiente para cada clase, en lugar de un único modelo condicionado a las cuatro categorías simultáneamente. Esta decisión permite que cada Generador se especialice en capturar las características morfológicas específicas de su clase correspondiente.

El Generador está compuesto por una serie de capas de convolución transpuesta que expanden progresivamente un vector latente de dimensión 100 hasta producir una imagen de 64×64 píxeles en escala de grises, empleando normalización por lotes (batch normalization) y activación ReLU en las capas intermedias, y una activación Tanh en la capa de salida. El Discriminador, por su parte, sigue una arquitectura simétrica inversa basada en capas convolucionales con activación LeakyReLU, reduciendo progresivamente la imagen de entrada hasta un único valor de probabilidad mediante una activación Sigmoide.

El entrenamiento se realizó utilizando el optimizador Adam ($\beta_1 = 0.5$, $\beta_2 = 0.999$) con una tasa de aprendizaje de 0.0002 para ambas redes, consistente con los valores reportados como estables en la literatura de DCGAN. Se empleó la función de pérdida de Entropía Cruzada Binaria (Binary Cross-Entropy) y un tamaño de lote de 64 imágenes. Cada modelo se entrenó durante 250 épocas, con un tiempo de entrenamiento promedio de 49.0 minutos por clase (rango: 47.8–50.5 minutos), utilizando una GPU NVIDIA T4 a través de la plataforma Google Colaboratory. Durante el entrenamiento se observó el comportamiento adversarial esperado entre ambas redes, caracterizado por oscilaciones en las funciones de pérdida del Generador y el Discriminador, sin evidenciarse colapso de modo (mode collapse) sostenido en ninguna de las cuatro clases entrenadas. Esta vigilancia resulta particularmente relevante en el contexto de imágenes biomédicas, donde Saad et al. (2024) identifican el colapso de modo y la inestabilidad del entrenamiento adversarial como dos de los principales desafíos que comprometen la utilidad de las imágenes sintéticas generadas mediante GAN en este dominio.

3.3.2. Proporción de Aumento de Datos Sintéticos

Con el fin de evitar que un volumen excesivo de imágenes sintéticas diluyera las características estadísticas del conjunto de datos real, se adoptó una proporción de aumento del 30%, generando 600 imágenes sintéticas por clase a partir de las 2,000 imágenes reales correspondientes a cada categoría diagnóstica. Esta proporción se ubica dentro del rango de 20%–50% reportado en estudios similares de aumento de datos basado en GAN para imágenes médicas, evitando tanto una contribución insuficiente del componente sintético como un posible riesgo de sobre-representación de patrones generados artificialmente.

3.3.3. Escenarios Experimentales (A: Sin GAN / B: Con GAN)

Con el propósito de evaluar el impacto del aumento de datos sintéticos sobre el desempeño de las cuatro arquitecturas de clasificación, se definieron dos escenarios experimentales:

- **Escenario A (sin GAN):** conjunto de entrenamiento compuesto únicamente por las 2,000 imágenes reales por clase descritas en la Sección 3.1, totalizando 8,000 imágenes de entrenamiento.
- **Escenario B (con GAN):** conjunto de entrenamiento compuesto por las mismas 2,000 imágenes reales por clase del Escenario A, adicionadas con las 600 imágenes sintéticas generadas por el modelo DCGAN correspondiente, totalizando 2,600 imágenes por clase (10,400 imágenes de entrenamiento en total).

Es importante señalar que los conjuntos de validación y prueba se mantuvieron idénticos y compuestos exclusivamente por imágenes reales en ambos escenarios, con el fin de garantizar que las diferencias observadas en el desempeño de los modelos fueran exclusivamente atribuibles a la composición del conjunto de entrenamiento, y no a variaciones en los criterios de evaluación. Asimismo, las técnicas de aumento de datos tradicional (descritas en la Sección 3.1) se aplicaron de manera idéntica en ambos escenarios, de forma que la única variable diferenciadora entre A y B fuera exclusivamente la presencia o ausencia de imágenes sintéticas generadas mediante GAN.

3.4. Protocolo de Entrenamiento e Hiperparámetros

El entrenamiento de las cuatro arquitecturas evaluadas se realizó bajo un protocolo común, con el fin de garantizar la validez del análisis comparativo entre ellas. Cada arquitectura fue entrenada de manera independiente para los dos escenarios experimentales definidos (Sección 3.3.3), resultando en un total de ocho configuraciones de entrenamiento.

Se empleó el optimizador Adam, con una tasa de aprendizaje de 0.0001, valor consistente con lo reportado en la literatura para tareas de clasificación de imágenes OCT mediante transferencia de aprendizaje. El tamaño de lote (batch size) se estableció en 32 imágenes, y la función de pérdida utilizada fue Entropía Cruzada (Cross-Entropy Loss), apropiada para el problema de clasificación multiclase abordado (cuatro categorías diagnósticas).

Con el fin de evitar el sobreajuste y optimizar el uso de recursos computacionales, se implementó una estrategia de detención temprana (early stopping) con un criterio de paciencia de ocho épocas, monitoreando la pérdida sobre el conjunto de validación. Esta medida de regularización resulta especialmente pertinente en el entrenamiento de redes profundas sobre conjuntos de imágenes médicas de tamaño moderado, dado que, como señalan Zhu et al. (2024), dichos modelos son particularmente susceptibles al sobreajuste cuando el volumen de datos de entrenamiento es limitado en relación con la capacidad del modelo. El número máximo de épocas se estableció en 50; sin embargo, ninguna de las ocho configuraciones alcanzó este límite, deteniéndose entre las épocas 12 y 50 según el comportamiento de convergencia particular de cada arquitectura y escenario (Tabla 1). Se conservaron los pesos correspondientes a la época de menor pérdida de validación observada durante el entrenamiento, en lugar de los pesos de la última época, con el objetivo de retener la configuración con mejor capacidad de generalización.

Todos los experimentos se ejecutaron en el entorno de Google Colaboratory, utilizando una unidad de procesamiento gráfico (GPU) NVIDIA T4.

Tabla 1. Hiperparámetros de entrenamiento empleados para las cuatro arquitecturas evaluadas.

Hiperparámetro	Valor
Optimizador	Adam
Tasa de aprendizaje	0.0001
Tamaño de lote (<i>batch size</i>)	32
Función de pérdida	Entropía Cruzada (<i>Cross-Entropy</i>)
Épocas máximas	50
Paciencia (<i>early stopping</i>)	8 épocas
Criterio de selección del modelo	Menor pérdida de validación

3.5. Métricas de Evaluación

El desempeño de cada configuración experimental fue evaluado sobre el conjunto de prueba (Sección 3.1), empleando las siguientes métricas estándar para problemas de clasificación multiclase:

- **Exactitud (Accuracy):** proporción de predicciones correctas sobre el total de observaciones evaluadas.
- **Precisión (Precision):** proporción de predicciones positivas correctas para una clase determinada, calculada mediante promedio macro entre las cuatro categorías diagnósticas, otorgando igual peso a cada clase independientemente de su frecuencia.
- **Sensibilidad (Recall):** proporción de casos positivos reales correctamente identificados, calculada de igual manera mediante promedio macro.
- **Puntaje F1 (F1-score):** media armónica entre Precisión y Sensibilidad, igualmente promediada de forma macro.
- **Área bajo la curva ROC (AUC-ROC):** calculada mediante la estrategia uno-contra-todos (One-vs-Rest), apropiada para problemas de clasificación con más de dos clases, y promediada de forma macro entre las cuatro categorías.

Adicionalmente, se generaron matrices de confusión para cada una de las ocho configuraciones, con el fin de identificar patrones específicos de confusión entre categorías diagnósticas, y curvas ROC individuales por clase para examinar la capacidad discriminativa de cada modelo de manera más granular.

3.6. Validación Estadística

Con el objetivo de determinar si las diferencias de desempeño observadas entre los Escenarios A y B (Sección 3.3.3) para cada arquitectura resultaban estadísticamente significativas, o si por el contrario podían atribuirse a variabilidad aleatoria, se aplicó la prueba de McNemar (McNemar, 1947) sobre las predicciones del conjunto de prueba.

A diferencia de pruebas que comparan proporciones de manera independiente, la prueba de McNemar resulta apropiada en este contexto debido a que las predicciones de ambos escenarios se evaluaron sobre el mismo conjunto de prueba, constituyendo así observaciones pareadas. Para cada arquitectura, se construyó una tabla de contingencia 2×2 a partir de los casos en que los Escenarios A y B discreparon en su predicción (es decir, uno de los dos clasificó correctamente la imagen mientras el otro no), ignorando los casos de acuerdo entre ambos. Se utilizó la aproximación mediante estadístico chi-cuadrado con corrección de continuidad, considerando un nivel de significancia $\alpha = 0.05$.

3.7. Interpretabilidad con Grad-CAM

Con el propósito de examinar las regiones de la imagen en las que cada arquitectura fundamenta sus predicciones, se aplicó la técnica Grad-CAM (Gradient-weighted Class Activation Mapping), propuesta por Selvaraju et al. (2019), mediante la implementación de código abierto pytorch-grad-cam.

Dada la naturaleza estructural diferenciada de las arquitecturas evaluadas, la capa objetivo (target layer) sobre la cual se calculó el mapa de activación varió según el tipo de arquitectura: para ResNet-50 y EfficientNet-B3, arquitecturas puramente convolucionales, se utilizó la última capa

convolucional de cada red, donde las activaciones conservan de forma nativa una estructura espacial bidimensional. Para ViT-B/16, dado que su mecanismo de auto-atención no preserva una estructura espacial convencional, fue necesario aplicar una transformación de reorganización (reshape transform) sobre las activaciones de la capa de normalización previa al último bloque de atención, descartando el token de clasificación (class token) y reorganizando los 196 tokens restantes en una representación espacial de 14×14 . Para CoAtNet, al tratarse de una arquitectura híbrida cuyo último bloque conserva una estructura de atención espacialmente consciente (Attention2d), se utilizó dicha capa sin requerir transformación adicional.

Para cada una de las cuatro categorías diagnósticas, se seleccionó una imagen representativa del conjunto de prueba y se generó su correspondiente mapa de calor para las ocho configuraciones evaluadas, permitiendo un análisis comparativo cualitativo de los patrones de atención entre arquitecturas convolucionales y basadas en atención (Sección 5.3).

4. RESULTADOS EXPERIMENTALES

4.1. Resultados de Línea Base: Escenario A (Sin GAN)


En el Escenario A, las cuatro arquitecturas evaluadas alcanzaron niveles de desempeño elevados sobre el conjunto de prueba (968 imágenes, 242 por categoría diagnóstica), con valores de exactitud (Accuracy) comprendidos entre 96.18% y 98.76% (Tabla 2). ViT-B/16 obtuvo el desempeño más alto en este escenario (Accuracy = 0.9876; F1-score macro = 0.9876; AUC-ROC = 0.9987), seguido de cerca por CoAtNet (Accuracy = 0.9845) y ResNet-50 (Accuracy = 0.9866). EfficientNet-B3 presentó el desempeño comparativamente más bajo de las cuatro arquitecturas (Accuracy = 0.9618; F1-score macro = 0.9618), una diferencia de aproximadamente 2.6 puntos porcentuales respecto a la arquitectura de mejor desempeño, a pesar de haber completado la totalidad de las 50 épocas de entrenamiento sin activación del criterio de detención temprana (Sección 4.3, Tabla 4), lo cual sugiere una convergencia más lenta de esta arquitectura bajo el protocolo de entrenamiento empleado.

Estos resultados son consistentes con el rango de desempeño reportado en estudios previos sobre el mismo conjunto de datos. Kermany et al. (2018) lograron una exactitud de 96.6% mediante transferencia de aprendizaje en la clasificación de las mismas cuatro categorías diagnósticas (CNV, DME, Drusen y Normal), valor cercano al obtenido por EfficientNet-B3 en el presente estudio, mientras que las exactitudes superiores al 98% obtenidas por ResNet-50, ViT-B/16 y CoAtNet se aproximan a los niveles reportados por enfoques más recientes sobre este mismo conjunto de datos. En esta línea, Miladinović et al. (2024) evaluaron diversas arquitecturas de aprendizaje profundo para la clasificación de imágenes OCT bajo condiciones de datos limitados y etiquetas con ruido, encontrando que el desempeño de los modelos puede degradarse sustancialmente fuera de condiciones experimentales controladas, lo cual subraya la relevancia de evaluar, como se hace en el presente estudio, el comportamiento de las arquitecturas bajo un volumen de datos reales deliberadamente acotado (Sección 3.1).


Tabla 2. Métricas de desempeño por arquitectura, Escenario A (sin aumento de datos vía GAN).

Arquitectura	Accuracy	Precision (macro)	Recall (macro)	F1-score (macro)
CoAtNet	0.9845	0.9846	0.9845	0.9845

EfficientNet-B3	0.9618	0.9622	0.9618	0.9618
ResNet-50	0.9866	0.9866	0.9866	0.9866
ViT-B/16	0.9876	0.9877	0.9876	0.9876



Matrices de confusión de las cuatro arquitecturas en el Escenario A




Curvas ROC -Escenario A

4.2. Resultados con Datos Sintéticos: Escenario B (Con GAN)


En el Escenario B, las cuatro arquitecturas mantuvieron niveles de desempeño igualmente elevados, con valores de exactitud entre 95.66% y 98.86% (Tabla 3). A diferencia del Escenario A, en este escenario ResNet-50 obtuvo el mejor desempeño global (Accuracy = 0.9917; F1-score macro = 0.9917), seguido de ViT-B/16 (Accuracy = 0.9886). CoAtNet y EfficientNet-B3 presentaron, en cambio, una disminución leve respecto a sus resultados en el Escenario A (de 0.9845 a 0.9824, y de 0.9618 a 0.9566, respectivamente).

Tabla 3. Métricas de desempeño por arquitectura, Escenario B (con aumento de datos vía GAN).


Arquitectura	Accuracy	Precision (macro)	Recall (macro)	F1-score (macro)
CoAtNet	0.9824	0.9825	0.9824	0.9824
EfficientNet-B3	0.9566	0.9566	0.9566	0.9565
ResNet-50	0.9917	0.9918	0.9917	0.9917
ViT-B/16	0.9886	0.9889	0.9886	0.9886



Matrices de confusión de las cuatro arquitecturas en el Escenario B



[FIGURA 4 — aquí]: Curvas ROC por clase de las cuatro arquitecturas en el Escenario B.



4.3. Análisis de Eficiencia Computacional

Tabla 4. Eficiencia computacional por configuración experimental.

Arquitectura	Escenario	Épocas hasta convergencia	Tiempo de entrenamiento (min)	Tiempo de inferencia por imagen (ms)	Parámetros totales	Parámetros entrenables
CoAtNet	A	15	19.91	8.211	26,669,638	12,855,880
CoAtNet	B	18	26.74	7.171	26,669,638	12,855,880
EfficientNet-B3	A	50*	104.66	6.083	10,702,380	599,044

EfficientNet-B3	B	50*	156.65	8.018	10,702,380	599,044
ResNet-50	A	12	43.44	7.565	23,516,228	14,972,932
ResNet-50	B	23	61.21	7.552	23,516,228	14,972,932
ViT-B/16	A	23	62.42	11.619	85,801,732	7,090,948
ViT-B/16	B	15	42.06	12.087	85,801,732	7,090,948


*EfficientNet-B3 alcanzó el límite máximo de 50 épocas sin activación del criterio de detención temprana.

Un hallazgo relevante de este análisis es que el número de parámetros del modelo no resultó ser un predictor directo del tiempo de entrenamiento. CoAtNet, con 26.7 millones de parámetros totales, presentó consistentemente los tiempos de entrenamiento más bajos de las cuatro arquitecturas, mientras que EfficientNet-B3, con un número de parámetros considerablemente menor (10.7 millones), requirió el mayor tiempo de entrenamiento, atribuible a que esta arquitectura no activó el mecanismo de detección temprana en ninguno de los dos escenarios, completando las 50 épocas en su totalidad. En cuanto al tiempo de inferencia, ViT-B/16 —la arquitectura con mayor cantidad de parámetros totales (85.8 millones, aproximadamente 3.2 veces más que CoAtNet)— presentó consistentemente los tiempos de inferencia por imagen más altos (11.6–12.1 ms), evidenciando el costo computacional asociado a su mecanismo de auto-atención global.

4.4. Resultados de Interpretabilidad con Grad-CAM

El análisis cualitativo de los mapas de activación generados mediante Grad-CAM reveló diferencias sustanciales en los patrones de atención entre las arquitecturas puramente convolucionales (ResNet-50, EfficientNet-B3) y aquellas basadas en mecanismos de atención (ViT-B/16, CoAtNet). En las arquitecturas convolucionales, los mapas de calor se concentraron de manera consistente en regiones anatómicamente compactas y delimitadas, coincidentes con las zonas de anomalía estructural esperadas para cada categoría diagnóstica; por ejemplo, la región de protuberancia central característica de la neovascularización coroidea (CNV), o la zona de engrosamiento retiniano asociada al edema macular diabético (DME).

En contraste, los mapas de activación de ViT-B/16 y CoAtNet exhibieron un patrón de atención considerablemente más disperso, con múltiples focos de activación distribuidos a lo largo de la imagen, incluyendo en ocasiones regiones de fondo sin contenido tisular relevante. Este comportamiento es consistente con la naturaleza del mecanismo de auto-atención global de los Transformers, el cual, a diferencia de las convoluciones locales, no impone restricciones espaciales sobre las regiones que pueden contribuir a la predicción final.



4.5. Análisis de Significancia Estadística

Los resultados de la prueba de McNemar aplicada a las predicciones del conjunto de prueba (Tabla 5) no evidenciaron diferencias estadísticamente significativas entre los Escenarios A y B para ninguna de las cuatro arquitecturas evaluadas ($p > 0.05$ en todos los casos).

Tabla 5. Resultados de la prueba de McNemar (Escenario A vs. Escenario B) por arquitectura.

Arquitectura	Solo A correcto	Solo B correcto	Estadístico χ^2	p-valor	Significativo ($\alpha=0.05$)
ResNet-50	5	10	1.067	0.302	No
EfficientNet-B3	18	13	0.516	0.472	No
ViT-B/16	9	10	0.000	1.000	No
CoAtNet	9	7	0.063	0.803	No

Si bien ResNet-50 mostró la mayor diferencia numérica entre escenarios, con el doble de casos en los que únicamente el Escenario B clasificó correctamente la imagen respecto a los casos en que solo el Escenario A lo hizo (10 frente a 5), esta diferencia no alcanzó significancia estadística ($\chi^2 = 1.067$; $p = 0.302$) bajo el tamaño de muestra evaluado (968 imágenes de prueba). Estos resultados indican que, para el volumen de datos reales y la proporción de aumento sintético empleados en el presente estudio (Sección 3.3.2), la incorporación de imágenes generadas mediante GAN no produjo una mejora ni un deterioro estadísticamente significativo en el desempeño de clasificación de ninguna de las cuatro arquitecturas evaluadas.

5. DISCUSIÓN

5.1. Rendimiento Comparativo entre Arquitecturas

Los resultados obtenidos en el presente estudio evidencian que las cuatro arquitecturas evaluadas son capaces de alcanzar niveles de desempeño clínicamente relevantes en la clasificación de imágenes OCT retinianas, con valores de exactitud que oscilaron entre 95.66% y 99.17% a través de los dos escenarios experimentales (Secciones 4.1 y 4.2). Sin embargo, el patrón de desempeño no favoreció de manera consistente a un único paradigma arquitectónico. En el Escenario A, ViT-B/16 obtuvo el mejor desempeño global, mientras que en el Escenario B fue ResNet-50 quien lideró las métricas, lo cual sugiere que la superioridad relativa entre arquitecturas convolucionales y basadas en atención no es absoluta, sino que depende de las condiciones específicas de entrenamiento.

Resulta particularmente notable que EfficientNet-B3, a pesar de poseer un número de parámetros entrenables considerablemente menor a las demás arquitecturas (Tabla 4), presentó el desempeño comparativamente más bajo en ambos escenarios. Este hallazgo es consistente con lo señalado en revisiones recientes sobre arquitecturas híbridas y basadas en atención, donde se advierte que la eficiencia paramétrica de una arquitectura no garantiza necesariamente una convergencia más rápida ni un mejor desempeño final, particularmente cuando el protocolo de entrenamiento no se ajusta de manera específica a las características de cada modelo (Kim et al., 2025). En este sentido, el hecho de que EfficientNet-B3 fuese la única arquitectura que no activó el criterio de detención temprana en ninguno de los dos escenarios (Tabla 4) sugiere que dicha arquitectura podría beneficiarse de un mayor número de épocas o de un ajuste diferenciado en su tasa de aprendizaje, en lugar de interpretarse como una limitación inherente del modelo.

Por su parte, CoAtNet, como arquitectura híbrida que integra mecanismos convolucionales y de atención (Sección 3.2.4), mostró un desempeño competitivo y los tiempos de entrenamiento más eficientes de las cuatro arquitecturas evaluadas, lo cual respalda el planteamiento de Dai et al. (2021) respecto a que el apilamiento estructurado de bloques convolucionales y de atención puede capitalizar las fortalezas de ambos paradigmas. No obstante, este desempeño no fue uniformemente superior a las arquitecturas no híbridas, lo cual matiza la noción de que los modelos híbridos constituyen necesariamente una mejora generalizada sobre sus contrapartes especializadas, en línea con lo discutido por Aburass et al. (2025) respecto a que la elección de arquitectura óptima en el análisis de imágenes médicas depende en gran medida de las características específicas de la tarea y del conjunto de datos.

5.2. Impacto del Aumento de Datos con GAN

Uno de los hallazgos centrales del presente estudio es que la incorporación de imágenes sintéticas generadas mediante DCGAN no produjo mejoras estadísticamente significativas en el desempeño de clasificación de ninguna de las cuatro arquitecturas evaluadas (Sección 4.5). Si bien ResNet-50 y ViT-B/16 mostraron mejoras numéricas modestas en el Escenario B, y CoAtNet y EfficientNet-B3 presentaron disminuciones igualmente modestas, la prueba de McNemar indicó que ninguna de estas diferencias supera el umbral de significancia estadística convencional ($p < 0.05$).

Este resultado contrasta con la expectativa intuitiva de que el aumento de datos sintéticos mejora de manera consistente el desempeño de los modelos de clasificación. Una posible explicación radica en el volumen del conjunto de datos reales empleado en este estudio: con 2,000 imágenes por clase en el

conjunto de entrenamiento, el dataset ya poseía una diversidad suficiente para que las arquitecturas, mediante transferencia de aprendizaje, alcanzaran niveles de desempeño cercanos a la saturación (superiores al 95% de exactitud en todos los casos), dejando un margen reducido de mejora que las 600 imágenes sintéticas adicionales por clase (30% de aumento) no lograron capitalizar de manera estadísticamente detectable.

Esta interpretación es consistente con los desafíos documentados en la literatura reciente sobre el uso de GAN en el aumento de datos biomédicos. Saad et al. (2024) señalan que, más allá de la calidad visual de las imágenes generadas, la utilidad real de los datos sintéticos para mejorar tareas posteriores de clasificación no está garantizada, y depende de factores como la diversidad efectiva capturada por el modelo generativo y la proporción de aumento empleada. En esta línea, durante el entrenamiento del modelo DCGAN para la clase Drusen se observó un comportamiento de pérdidas comparativamente más inestable hacia las épocas finales en relación con las demás clases (Sección 3.3.1), lo cual, sin constituir un colapso de modo manifiesto en las imágenes generadas, podría haber limitado la diversidad efectiva de las muestras sintéticas correspondientes a dicha categoría diagnóstica.

5.3. Interpretabilidad y Confiabilidad Clínica

El análisis de interpretabilidad mediante Grad-CAM (Sección 4.4) reveló una distinción cualitativa relevante entre los paradigmas arquitectónicos evaluados: las arquitecturas convolucionales (ResNet-50, EfficientNet-B3) generaron mapas de activación compactos y anatómicamente coherentes, mientras que las arquitecturas basadas en atención (ViT-B/16, CoAtNet) produjeron mapas considerablemente más dispersos, con focos de activación distribuidos incluso en regiones sin contenido tisular relevante.

Esta diferencia tiene implicaciones que trascienden la métrica de exactitud y se vinculan directamente con la confiabilidad clínica de los modelos. En un contexto de aplicación médica real, un especialista no solo requiere que el modelo prediga correctamente, sino que la explicación subyacente sea clínicamente verosímil y permita auditar la decisión del sistema. Bajo esta perspectiva, el hecho de que ViT-B/16 obtuviera el segundo mejor desempeño cuantitativo del estudio, pero generara explicaciones visuales menos focalizadas, evidencia una tensión entre exactitud predictiva e interpretabilidad: un trade-off señalado en estudios previos sobre revisión sistemática de arquitecturas híbridas en imagenología radiológica, donde se destaca que los mecanismos de auto-atención global, si bien potencian la capacidad discriminativa del modelo, dificultan la generación de explicaciones espacialmente localizadas mediante métodos post-hoc diseñados originalmente para arquitecturas convolucionales (Kim et al., 2025).

Esta observación sugiere que la selección de una arquitectura para aplicaciones clínicas no debería basarse exclusivamente en métricas de desempeño agregadas, sino considerar también la calidad y verosimilitud de las explicaciones generadas, particularmente en escenarios donde la adopción clínica depende de la confianza del especialista en el razonamiento del sistema.

5.4. Comparación con el Estado del Arte

Los niveles de exactitud obtenidos en el presente estudio (95.66%–99.17%) se encuentran dentro del rango reportado en la literatura reciente sobre clasificación de imágenes OCT retinianas mediante aprendizaje profundo. El desempeño de EfficientNet-B3 (95.66%–96.18%) resulta cercano al 96.6%

reportado originalmente por Kermany et al. (2018) mediante transferencia de aprendizaje sobre el mismo conjunto de datos, mientras que los desempeños superiores al 98% obtenidos por ResNet-50, ViT-B/16 y CoAtNet se aproximan a los niveles alcanzados por enfoques más recientes y especializados.

No obstante, esta comparación debe interpretarse con cautela. Miladinović et al. (2024) advierten que el desempeño reportado en estudios de clasificación de OCT puede variar sustancialmente según las condiciones experimentales (en particular, la presencia de etiquetas con ruido y la disponibilidad limitada de datos), lo cual dificulta una comparación estrictamente equivalente entre estudios que emplean particiones, preprocesamiento y criterios de validación distintos. En este sentido, el presente estudio se distingue de buena parte de la literatura previa al evaluar explícitamente cuatro paradigmas arquitectónicos bajo un protocolo experimental común y al incorporar una evaluación estadística formal (prueba de McNemar) del efecto del aumento de datos sintéticos, aspecto que, conforme a las revisiones realizadas en el proceso de búsqueda bibliográfica del presente trabajo, no se encuentra sistemáticamente reportado en estudios comparables.

5.5. Limitaciones del Estudio

El presente estudio presenta varias limitaciones que deben considerarse al interpretar sus hallazgos. En primer lugar, el conjunto de datos de entrenamiento, si bien fue deliberadamente acotado a 2,000 imágenes por clase para simular condiciones de escasez de datos médicos (Sección 3.1), proviene de una única fuente institucional (Kermany et al., 2018), lo cual podría limitar la generalización de los modelos a imágenes OCT adquiridas con equipos o protocolos de distintos centros clínicos.

En segundo lugar, la estrategia de ajuste fino parcial empleada en las cuatro arquitecturas, si bien está respaldada por la literatura como una práctica adecuada para mitigar el sobreajuste en contextos de datos limitados (Ayana et al., 2024), implica que una porción sustancial de los parámetros de cada modelo permaneció congelada durante el entrenando, lo cual pudo haber restringido la capacidad de adaptación de las arquitecturas (particularmente ViT-B/16 y CoAtNet) a las características específicas del dominio OCT, dado que estas arquitecturas suelen requerir mayores volúmenes de datos para un ajuste fino completo y efectivo.

En tercer lugar, la proporción de aumento de datos sintéticos evaluada (30%) constituye un único punto dentro de un espacio de configuraciones posibles; no puede descartarse que proporciones distintas, o estrategias de generación más sofisticadas que el DCGAN empleado (como las arquitecturas Wasserstein GAN con penalización de gradiente o GAN condicionales mencionadas en la literatura reciente), pudieran producir efectos estadísticamente detectables que no se manifestaron bajo la configuración específica de este estudio.

Finalmente, la evaluación de interpretabilidad mediante Grad-CAM (Sección 4.4) se limitó a un análisis cualitativo sobre una imagen representativa por clase, sin incorporar una validación cuantitativa de la concordancia entre las regiones destacadas por los mapas de activación y anotaciones clínicas de referencia, lo cual limita la posibilidad de establecer conclusiones definitivas sobre la fidelidad clínica de las explicaciones generadas por cada arquitectura.

6. CONCLUSIONES

El presente estudio realizó un análisis comparativo de cuatro arquitecturas de aprendizaje profundo: ResNet-50, EfficientNet-B3, ViT-B/16 y CoAtNet; para la clasificación de imágenes de tomografía de coherencia óptica (OCT) retiniana en cuatro categorías diagnósticas (CNV, DME, Drusen y Normal), evaluando adicionalmente el efecto del aumento de datos sintéticos generados mediante una red generativa adversarial (DCGAN) bajo dos escenarios experimentales controlados.

Los resultados muestran que las cuatro arquitecturas son capaces de alcanzar niveles de exactitud clínicamente relevantes (entre 95.66% y 99.17%), sin que ningún paradigma arquitectónico demuestre una superioridad consistente y absoluta sobre los demás. ViT-B/16 obtuvo el mejor desempeño en el escenario sin aumento de datos, mientras que ResNet-50 lo obtuvo en el escenario con aumento de datos, lo cual indica que la selección de la arquitectura óptima depende de las condiciones específicas de entrenamiento y no puede generalizarse de manera universal a partir de una sola configuración experimental.

En relación con la pregunta de investigación central de este estudio, los hallazgos indican que la incorporación de imágenes sintéticas generadas mediante GAN no produjo mejoras ni deterioros estadísticamente significativos en el desempeño de clasificación de ninguna de las cuatro arquitecturas evaluadas, conforme a la prueba de McNemar aplicada. Este resultado matiza la suposición frecuente de que el aumento de datos sintéticos constituye una mejora garantizada, y sugiere que su efectividad está condicionada por factores como el volumen y diversidad del conjunto de datos reales disponible, la proporción de aumento empleada, y la estabilidad del proceso de entrenamiento adversarial.

El análisis de interpretabilidad mediante Grad-CAM evidenció que las arquitecturas convolucionales producen explicaciones visuales más focalizadas y anatómicamente coherentes que las arquitecturas basadas en atención, lo cual constituye una consideración relevante para la adopción clínica de estos modelos, más allá de su desempeño cuantitativo. Asimismo, el análisis de eficiencia computacional reveló que el número de parámetros de una arquitectura no constituye un predictor directo de su tiempo de entrenamiento ni de inferencia, hallazgo que resulta de utilidad práctica para la selección de arquitecturas en contextos con recursos computacionales limitados.

En conjunto, estos resultados sugieren que la decisión sobre qué arquitectura emplear en tareas de clasificación de imágenes médicas debe fundamentarse en un análisis multidimensional que considere no solo la exactitud predictiva, sino también la eficiencia computacional y la interpretabilidad de las explicaciones generadas, particularmente en dominios clínicos donde la confianza del especialista en el sistema es tan relevante como su desempeño numérico. Como líneas de trabajo futuro, se sugiere explorar distintas proporciones de aumento de datos sintéticos, así como arquitecturas generativas más avanzadas, y extender la validación de los modelos a conjuntos de datos provenientes de múltiples centros clínicos.

REFERENCIAS

- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>

- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning*, 97, 6105–6114.
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). *An image is worth 16x16 words: Transformers for image recognition at scale*. arXiv. <https://doi.org/10.48550/arXiv.2010.11929>
- Dai, Z., Liu, H., Le, Q. V., & Tan, M. (2021). CoAtNet: Marrying convolution and attention for all data sizes. *Advances in Neural Information Processing Systems*, 34, 3965–3977.
- Radford, A., Metz, L., & Chintala, S. (2015). *Unsupervised representation learning with deep convolutional generative adversarial networks*. arXiv. <https://doi.org/10.48550/arXiv.1511.06434>
- Yang, M., Du, J., & Lv, R. (2025b). CRAT: Advanced transformer-based deep learning algorithms in OCT image classification. *Biomedical Signal Processing And Control*, 104, 107544. <https://doi.org/10.1016/j.bspc.2025.107544>
- Gencer, G., & Gencer, K. (2025). Advanced retinal disease detection from OCT images using a hybrid squeeze and excitation enhanced model. *PLoS ONE*, 20(2), e0318657. <https://doi.org/10.1371/journal.pone.0318657>
- Abdi, A. S., & Abdulazeez, A. M. (2025). A comprehensive review of deep learning in OCT image segmentation and classification. *Medicine In Novel Technology And Devices*, 28, 100396. <https://doi.org/10.1016/j.medntd.2025.100396>
- P, S. A., Kar, S., S, G., Gopi, V. P., & Palanisamy, P. (2020). OctNET: A Lightweight CNN for Retinal Disease Classification from Optical Coherence Tomography Images. *Computer Methods And Programs In Biomedicine*, 200, 105877. <https://doi.org/10.1016/j.cmpb.2020.105877>
- Aburass, S., Dorgham, O., Shaqsi, J. A., Rumman, M. A., & Al-Kadi, O. (2025). Vision Transformers in Medical Imaging: a Comprehensive Review of Advancements and Applications Across Multiple Diseases. *Journal Of Imaging Informatics In Medicine*, 38(6), 3928-3971. <https://doi.org/10.1007/s10278-025-01481-y>
- Ahmed, F., & Uddin, M. J. (2025b). OcuViT: A Vision Transformer-Based Approach for Automated Diabetic Retinopathy and AMD Classification. *Journal Of Imaging Informatics In Medicine*, 39(3), 2511-2521. <https://doi.org/10.1007/s10278-025-01676-3>
- Cutur, E. S., & Inan, N. G. (2025b). Multi-class Classification of Retinal Eye Diseases from Ophthalmoscopy Images Using Transfer Learning-Based Vision Transformers. *Journal Of Imaging Informatics In Medicine*, 38(5), 3110-3124. <https://doi.org/10.1007/s10278-025-01416-7>
- Goh, J. H. L., Ang, E., Srinivasan, S., Lei, X., Loh, J., Quek, T. C., Xue, C., Xu, X., Liu, Y., Cheng, C., Rajapakse, J. C., & Tham, Y. (2024b). Comparative Analysis of Vision Transformers and Conventional Convolutional Neural Networks in Detecting Referable Diabetic Retinopathy. *Ophthalmology Science*, 4(6), 100552. <https://doi.org/10.1016/j.xops.2024.100552>
- Arbab, A., Habibi, A., Rabbani, H., & Tajmiriahi, M. (2025b). From Image to Sequence: Exploring Vision Transformers for Optical Coherence Tomography Classification. *Journal Of Medical Signals & Sensors*, 15(6), 18. https://doi.org/10.4103/jmss.jmss_58_24
- Rajatha, & Ashoka, D. (2025). EffiViT: Hybrid CNN-Transformer for Retinal Imaging. *Computers In Biology And Medicine*, 191, 110164. <https://doi.org/10.1016/j.compbiomed.2025.110164>

- Kim, J. W., Khan, A. U., & Banerjee, I. (2025). Systematic Review of Hybrid Vision Transformer Architectures for Radiological Image Analysis. *Journal Of Imaging Informatics In Medicine*, 38(5), 3248-3262. <https://doi.org/10.1007/s10278-024-01322-4>
- Azad, R., Kazerooni, A., Heidari, M., Aghdam, E. K., Molaei, A., Jia, Y., Jose, A., Roy, R., & Merhof, D. (2023). Advances in medical image analysis with vision Transformers: A comprehensive review. *Medical Image Analysis*, 91, 103000. <https://doi.org/10.1016/j.media.2023.103000>
- Liu, Z., & Shen, L. (2023). CECT: Controllable Ensemble CNN and Transformer for COVID-19 Image Classification. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2302.02314>
- Anaya-Sánchez, H., Altamirano-Robles, L., Díaz-Hernández, R., & Zapotecas-Martínez, S. (2024). WGAN-GP for Synthetic Retinal Image Generation: Enhancing Sensor-Based Medical Imaging for Classification Models. *Sensors*, 25(1), 167. <https://doi.org/10.3390/s25010167>
- Ayana, G., Dese, K., Abagaro, A. M., Jeong, K. C., Yoon, S.-D., & Choe, S. (2024). Multistage transfer learning for medical images. *Artificial Intelligence Review*, 57(9), 232. <https://doi.org/10.1007/s10462-024-10855-7>
- Saad, M. M., O'Reilly, R., & Rehmani, M. H. (2024). A survey on training challenges in generative adversarial networks for biomedical image analysis. *Artificial Intelligence Review*, 57(2), 19. <https://doi.org/10.1007/s10462-023-10624-y>
- Mosquera, C., Ferrer, L., Milone, D. H., Luna, D., & Ferrante, E. (2024). Class imbalance on medical image classification: towards better evaluation practices for discrimination and calibration performance. *European Radiology*, 34, 7895–7903. <https://doi.org/10.1007/s00330-024-10834-0>
- Miladinović, A., Biscontin, A., Ajčević, M., et al. (2024). Evaluating deep learning models for classifying OCT images with limited data and noisy labels. *Scientific Reports*, 14, 30321. <https://doi.org/10.1038/s41598-024-81127-1>
- Zhu, S., Yu, C., & Hu, J. (2024). Regularizing deep neural networks for medical image analysis with augmented batch normalization. *Applied Soft Computing*, 154, 111337. <https://doi.org/10.1016/j.asoc.2024.111337>
- Chen, Y., Yang, X., Wei, Z., Heidari, A. A., Zheng, N., Li, Z., Chen, H., Hu, H., Zhou, Q., & Guan, Q. (2022). Generative Adversarial Networks in Medical Image augmentation: A review. *Computers In Biology And Medicine*, 144, 105382. <https://doi.org/10.1016/j.combiomed.2022.105382>
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2019). Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. *International Journal Of Computer Vision*, 128(2), 336-359. <https://doi.org/10.1007/s11263-019-01228-7>
- McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153–157. <https://doi.org/10.1007/BF02295996>
- Kermany, D. S., Goldbaum, M., Cai, W., Valentim, C. C. S., Liang, H., Baxter, S. L., McKeown, A., Yang, G., Wu, X., Yan, F., Dong, J., Prasadha, M. K., Pei, J., Ting, M. Y. L., Zhu, J., Li, C., Hewett, S., Dong, J., Ziyar, I., ... Zhang, K. (2018). Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell*, 172(5), 1122–1131.e9. <https://doi.org/10.1016/j.cell.2018.02.010>


- Steinmetz, J. D., Bourne, R. R. A., Briant, P. S., Flaxman, S. R., Taylor, H. R. B., Jonas, J. B., et al. (2021). Causes of blindness and vision impairment in 2020 and trends over 30 years, and prevalence of avoidable blindness in relation to VISION 2020: the Right to Sight: an analysis for the Global Burden of Disease Study. *The Lancet Global Health*, 9(2), e144–e160. [https://doi.org/10.1016/S2214-109X\(20\)30489-7](https://doi.org/10.1016/S2214-109X(20)30489-7)
- Daich Varela, M., Sen, S., De Guimaraes, T. A. C., Kabiri, N., Pontikos, N., Balaskas, K., & Michaelides, M. (2023). Artificial intelligence in retinal disease: clinical application, challenges, and future directions. *Graefe's Archive for Clinical and Experimental Ophthalmology*, 261(11), 3283–3297. <https://doi.org/10.1007/s00417-023-06052-x>

ANEXOS

Se elaboró el siguiente gráfico de barras que analiza los artículos que se han analizado, los cuales han sido recientes, se resalta el uso de artículos del 2024 y 2025.

Artículos por año

Distribución temporal de los artículos incluidos en la bibliografía.



Artículos por cuartil y tipo de publicación

Distribución de referencias según cuartil académico y tipo de publicación.

